

LAPD Crime Analysis

2010 — 2024

Project Brief

Progetto: Primo progetto portfolio strutturato

Framework: PACE (Plan, Analyze, Construct, Execute)

Dataset: LAPD Crime Data — data.lacity.org

Periodo: Gennaio 2010 — Dicembre 2024

Record: 3.079.424 (post-cleaning)

Stato attuale: Fase Plan completata, Fase Analyze in corso

Analisi esplorativa dei crimini registrati dal Los Angeles Police Department, basata sui dataset open data ufficiali. Il progetto si propone di identificare trend temporali, pattern geografici, profili demografici delle vittime e dinamiche specifiche come gli abusi domestici e la violenza armata.

1. Struttura del progetto

Il progetto segue il framework PACE appreso nei corsi Google Data Analytics su Coursera. Ogni fase ha obiettivi definiti, task tracciati e un summary document che chiude formalmente la fase.

Repository GitHub

Cartella	Contenuto	Git
data/raw/	CSV originali LAPD (~1 GB)	Ignorata
data/processed/	crimes_merged.parquet (134 MB), crimes_clean.parquet	Ignorata
notebooks/01_plan/ /	01_data_loading.ipynb, 03_research_questions.md, plan_summary.md	Versionata
notebooks/02_analyze/ /	02_cleaning.ipynb, analyze_summary.md	Versionata
notebooks/03_construct/ /	Da popolare	Versionata
notebooks/04_execute/ /	Da popolare	Versionata
outputs/	Grafici PNG esportati	Versionata
reports/	Relazione management + PPT	Versionata

Deliverable finali

- **Jupyter Notebook tecnico** — codice completo e commentato, su GitHub
- **Relazione Management** — sintesi non tecnica con visualizzazioni chiave
- **Presentazione PowerPoint** — slide con grafici reali esportati dall'analisi

2. Fase Plan — Risultati

Stato: Completata

Dataset originale

Due CSV scaricati da data.lacity.org: Crime Data 2010-2019 (circa 2M righe) e Crime Data 2020-2024 (circa 1M righe). Dopo la concatenazione: 3.138.031 righe e 28 colonne, circa 670 MB in memoria.

Problemi identificati e risolti

- **Disallineamento colonne:** la colonna AREA aveva uno spazio finale nel CSV 2010-2019. Risolto con normalizzazione dei nomi.
- **LAT/LON con separatore decimale incoerente:** il dataset 2010-2019 usa la virgola (formato europeo), il 2020-2024 usa il punto. Un primo tentativo di conversione diretta ha distrutto 2.1M di valori. Risolto con normalizzazione virgola-punto prima della conversione. Zero valori persi.
- **3.148 coordinate sentinella (0, 0):** identificate come valori per posizione sconosciuta. Range geografico verificato coerente con LA.

Decisioni chiave

- Periodo di analisi: **2010-2024 completo** (ampliato rispetto alla bozza iniziale 2015-2024)
- Formato intermedio: **Parquet** (compressione 7x, lettura 10x più veloce, tipi di dato preservati)
- Cleaning completo, non minimale, per supportare domande analitiche da definire progressivamente

Output

- **crimes_merged.parquet** (134 MB) — dataset concatenato con tipi consistenti

3. Fase Analyze — Cleaning

Stato: Cleaning completato. Feature engineering e EDA da iniziare.

Operazioni eseguite

Operazione	Dettaglio	Impatto
Eliminazione colonne	Crm Cd 2/3/4, Cross Street	28 a 24 col
Conversione date	DATE OCC, Date Rptd a datetime64	—
Conversione orari	TIME OCC (HHMM) a hour_occ (0-23)	Col sostituita
Coordinate sentinella	3.148 record (0,0) a NaN	0.10%
Duplicati esatti	57.809 righe identiche rimosse	-1.84%
Weapon nulli	Ricodificati come No Weapon / 0	66.73%
Vict Sex/Descent nulli	Ricodificati come X (Unknown)	10.95%
Vict Sex anomali	H, N, - ricodificati come X	204 record
Vict Age sentinelle	632.399 valori <= 0 a NaN	20.54%
Premis Desc nulli	Righe rimosse	-775 righe
Status/Crm Cd 1 nulli	Righe rimosse (pulizia residua)	-23 righe

Dataset finale

- **Righe:** 3.079.424
- **Colonne:** 24
- **Anni coperti:** 15 (2010-2024)
- **Aree LAPD:** 21
- **Tipi di crimine:** 143
- **Range DATE OCC:** 1 gen 2010 — 30 dic 2024
- **Range geografico:** LAT 33.34-34.79, LON -118.83 a -117.66

Scoperte rilevanti

- **Il 2024 non è troncato:** DATE OCC arriva al 30 dicembre 2024. I 127k record (vs ~230k attesi) rappresentano un calo reale di crimini registrati, non un troncamento del dataset.
- **Artefatto mezzanotte:** ~130k record con hour_occ = 0, probabilmente orario sconosciuto codificato come 0000.
- **Media Vict Age post-pulizia:** 38.8 anni (era 30.8 prima della rimozione dei sentinella 0).

Output

- **crimes_clean.parquet** — dataset pulito, pronto per feature engineering e EDA

4. Domande di ricerca

Le domande sono organizzate in 7 blocchi tematici divisi in due fasi: una fase core (analisi descrittive e diagnostiche, 15 domande) e una fase avanzata (modelli predittivi e analisi geospaziale, 7 domande).

Fase Core

Blocco 1 — Panoramica e trend temporali

- 1.1 Top 5 crimini più frequenti e trend anno per anno
- 1.2 Top 5 crimini contro la persona vs contro la proprietà e trend separati
- 1.3 Categorie con maggior crescita e decrescita YoY
- 1.4 Pattern stagionali per tipo di crimine (mensile)
- 1.5 Fasce orarie e giorni della settimana per area LAPD

Blocco 2 — Profilo demografico vittime

- 2.1 Distribuzione vittime per sesso, età, etnia (integrato per area)
- 2.2 Profilo vittime incrociato con tipologie di crimine
- 2.3 Focus vittime anziane (65+): tipologie di reato e aree

Blocco 3 — Abusi domestici e sicurezza minori

- 3.1 Panoramica reati domestici: volume, trend, distribuzione per area
- 3.2 Confronto profilo vittime: reati domestici vs non-domestici
- 3.3 Distribuzione per fasce: bambini (0-12), adolescenti (13-17), adulti (18+)
- 3.4 Pattern Mocodes nei reati domestici (richiede lookup table LAPD)

Blocco 4 — Reati con arma da fuoco

- 4.1 Distribuzione e trend armi da fuoco per area
- 4.2 Profilo vittime nei reati con arma da fuoco

Blocco 5 — Efficacia della risposta

- 5.1 Tasso di clearance per categoria di reato e area LAPD
- 5.2 Report delay (Date Rptd - DATE OCC) per tipo di reato e area

Fase Avanzata

Blocco 6 — Analisi geospaziale avanzata

- 6.1 Mappa hotspot su griglia 500m x 500m
- 6.2 Persistenza hotspot nel tempo (overlap mese su mese)
- 6.3 Clustering spaziale statistico (Moran's I, Getis-Ord Gi*)

Blocco 7 — Modelli predittivi

- 7.1 Previsione volume reati a 7 giorni (target MAPE < 15%)
- 7.2 Modello predittivo di clearance (Random Forest / Logistic Regression)

7.3 Co-occorrenza spazio-temporale tra tipologie di reato

7.4 Pattern di ri-vittimizzazione (stesso indirizzo entro 30/60/90 giorni)

5. Limitazioni del dataset

- **Dark figure of crime:** Il dataset riflette reati denunciati, non commessi. Aree con bassa fiducia verso la polizia sono sotto-rappresentate.
- **Cambiamenti classificatori:** Riforme come Prop 47 in California possono alterare i confronti longitudinali senza normalizzazione.
- **Missing rate non casuale:** I campi arma, etnia vittima e descrittori demografici hanno tassi di missing elevati e non casuali (MNAR).
- **Granularità geografica:** Le coordinate sono spesso offuscate al centroide del blocco, limitando la precisione sotto i ~100m.
- **Assenza dati di esposizione:** Il dataset non contiene dati di popolazione. I tassi per 1.000 residenti richiedono integrazione con dati census/ACS.
- **Artefatto mezzanotte:** ~130k record con orario 00:00, probabilmente codifica per orario sconosciuto.
- **Anomalie 2015-2016:** Calo anomalo nel 2015 e picco nel 2016, probabilmente legati alla transizione del sistema di classificazione LAPD.

6. Prossimi passi

- **Feature engineering:** creazione colonne derivate (anno, mese, giorno settimana, fascia oraria, gruppi età, macro-categorie crimine, decodifica Mocodes)
- **Definizione domande finali:** raffinamento delle domande in base alle feature disponibili dopo l'engineering
- **EDA:** analisi esplorativa strutturata per blocchi tematici
- **Visualizzazioni:** grafici statici (matplotlib/seaborn) e mappe interattive (folium) e statiche (geopandas)
- **Fase avanzata:** modelli predittivi e analisi geospaziale avanzata (da affrontare dopo la fase core)